

SUMÁRIO

# ANÁLISE DAS LDOS E LOAS MUNICIPAIS (ITEM 3.3 DA TESE)	2
## O que cada script faz	2
## Passo a passo para rodar (Windows/CMD)	3
Estrutura esperada (`C:\analyseldoloa`):	3
Passo 1 — Instalar o Python	3
Passo 2 — Instalar o Tesseract (OCR) com Português	3
Passo 3 — Instalar as bibliotecas (uma vez)	3
Passo 4 — Conferir os documentos	4
Passo 5 — Rodar a análise	4
Passo 6 (opcional) — Gerar os apêndices a partir dos parâmetros	4
Passo 7 (opcional) — Validação (kappa/F1)	4
## Rodando fora do Windows (Linux/Mac)	4
## Erros comuns	5
## O que o programa faz (resumo)	5
## Reprodutibilidade	5

ANÁLISE DAS LDOS E LOAS MUNICIPAIS (ITEM 3.3 DA TESE)

Código usado na tese de doutorado de Yasmin Viana ("Geoinformação e gestão pública municipal na Baixada Fluminense Histórica") para o item **3.3 — Análise das Leis de Diretrizes Orçamentárias (LDO) e Leis Orçamentárias Anuais (LOA)**, que mede o **Grau de Integração Orçamentária** da geoinformação nas peças orçamentárias dos 8 municípios da Baixada Fluminense Histórica.

O vocabulário, os pesos de força técnica, os temas, as listas de apoio (expressões de falso-positivo, termos fuzzy) e a rubrica de classificação usados por este código são os mesmos publicados nos Anexos A, B e C do `Texto-Tese-Modificado.docx` e ficam no arquivo `Parametros\_LDO\_LOA.xlsx`. Esse mesmo arquivo de parâmetros também é usado na análise dos instrumentos urbanísticos (pasta `../3.2\_Instrumentos\_Urbanisticos/`), pois os dois eixos compartilham parte do vocabulário técnico.

O QUE CADA SCRIPT FAZ

1. **analise_ldo_loa.py** — script principal. Lê os parâmetros de `Parametros\_LDO\_LOA.xlsx`, lê os PDFs das LDOs/LOAs organizados em pastas por município (com OCR via Tesseract nas páginas digitalizadas), busca o vocabulário técnico, classifica as ocorrências em dois eixos (força × ancoragem), pondera, deduplica, calcula os indicadores e o Grau de Integração Orçamentária, e grava tudo em `Resultados\_LDO\_LOA.xlsx` (com fórmulas, valores monetários candidatos por trecho e agregação por projeto/município/ano).
2. **Ferramentas_LDO_LOA.py** — funções utilitárias usadas pelo script principal (leitura de parâmetros, normalização de texto, extração monetária, etc.).
3. **gerar_apendices.py** *(opcional)* — gera um `.docx` com o vocabulário completo e o livro de código usados na análise, a partir de `Parametros\_LDO\_LOA.xlsx`, com um carimbo SHA-256 do arquivo de parâmetros (garante que o texto do apêndice bate exatamente com os parâmetros efetivamente usados na rodada).
4. **Harness_Validacao.py** *(opcional)* — ferramenta de validação inter-avaliadores: sorteia uma amostra dos resultados para dois avaliadores humanos rotularem manualmente, e depois calcula kappa de Cohen e F1 entre os rótulos humanos e a classificação automática (semente fixa `SEMENTE = 42`, para reprodutibilidade da amostragem).

PASSO A PASSO PARA RODAR (WINDOWS/CMD)

Pasta de trabalho recomendada: `C:\analyseldoloa` — os caminhos já vêm configurados no código apontando para essa pasta (ver "Área de alteração" no topo de `analise\_ldo\_loa.py`), então o mais simples é reproduzir essa estrutura exata. Coloque TODO o conteúdo desta pasta em `C:\analyseldoloa`.

ESTRUTURA ESPERADA (C:\ANALISELDOLOA):

```
...
C:\analyseldoloa\
  analise_ldo_loa.py
  Ferramentas_LDO_LOA.py
  gerar_apendices.py      (opcional)
  Harness_Validacao.py    (opcional)
  Parametros_LDO_LOA.xlsx (vocabulário e regras -- Anexos A, B, C da tese)
  requirements.txt
  BELFORD ROXO LOA E LDO\ (uma pasta por município; PDFs dentro)
    LDO - Belford Roxo - 2017.pdf
    LOA - Belford Roxo - 2017.pdf
  ...
  DÚQUE DE CAXIAS LOA E LDO\
  ... (demais municípios)
...
```

Os resultados são gravados em `C:\analyseldoloa\Resultados\_LDO\_LOA.xlsx`.

Passo 1 — Instalar o Python

Baixe o Python 3.12 em python.org/downloads. No instalador, marque "Add python.exe to PATH".
Confira no CMD: `py --version`.

Passo 2 — Instalar o Tesseract (OCR) com Português

Instale o "Tesseract OCR" (build da UB Mannheim). Em "Additional language data", marque "Portuguese". Caminho padrão esperado pelo código: `C:\Program Files\Tesseract-OCR` (o programa já procura automaticamente nesse caminho e em `C:\Program Files (x86)\Tesseract-OCR`).

Passo 3 — Instalar as bibliotecas (uma vez)

```
...
cd /d C:\analyseldoloa
py -m pip install -r requirements.txt
...
```

****Passo 4 — Conferir os documentos****

Coloque as pastas municipais (com os PDFs de LDO e LOA) dentro de `C:\analyseldoloa`, no mesmo padrão de nomes usado na tese (`<MUNICÍPIO> LOA E LDO\`). Confirme que `Parametros\_LDO\_LOA.xlsx` está em `C:\analyseldoloa` e está ****fechado**** no Excel (o script não consegue ler o arquivo se ele estiver aberto). Não é preciso editar o código: os caminhos já apontam para `C:\analyseldoloa`.

****Passo 5 — Rodar a análise****

```
'''
```

```
cd /d C:\analyseldoloa
py analyse_ldo_loa.py
'''
```

A primeira execução com OCR é demorada (pode levar horas em documentos grandes e escaneados).

Deixe terminar até aparecer "Concluído". Resultado: `C:\analyseldoloa\Resultados\_LDO\_LOA.xlsx`.

****Passo 6 (opcional) — Gerar os apêndices a partir dos parâmetros****

```
'''
```

```
py gerar_apendices.py Parametros_LDO_LOA.xlsx APENDICES.docx
'''
```

Gera o vocabulário e o livro de código com carimbo SHA-256 (garante que o texto bate com os parâmetros usados).

****Passo 7 (opcional) — Validação (kappa/F1)****

```
'''
```

```
py Harness_Validacao.py amostrar Resultados_LDO_LOA.xlsx amostra.xlsx
'''
```

Preencha à mão as colunas `rotulo\_humano\_1` e `rotulo\_humano\_2` em `amostra.xlsx`, depois:

```
'''
```

```
py Harness_Validacao.py avaliar amostra.xlsx relatorio_validacao.xlsx
'''
```

RODANDO FORA DO WINDOWS (LINUX/MAC)

O código foi escrito e documentado para Windows/CMD (ambiente em que a tese foi processada), com os caminhos de `Parametros\_LDO\_LOA.xlsx`, da pasta raiz e do Tesseract fixados no topo de `analise\_ldo\_loa.py` (bloco "ÁREA DE ALTERAÇÃO"). Para rodar em Linux ou Mac, edite esse bloco (linhas ~23-28) trocando os caminhos `C:\...` pelos caminhos equivalentes no seu sistema (por exemplo `/home/usuario/analyseldoloa/...`) e pelo caminho do binário `tesseract` do seu sistema (which tesseract). Fora isso, o restante do script é multiplataforma.

ERROS COMUNS

- `No module named ...` → repita o passo 3 (`py -m pip install -r requirements.txt`).
- `Tesseract não encontrado` → confirme o passo 2 e o idioma "por" instalado.
- `Permission denied` ao gravar a saída → feche `Resultados\_LDO\_LOA.xlsx` no Excel antes de rodar de novo.
- Erro lendo parâmetros → não renomeie abas ou cabeçalhos de `Parametros\_LDO\_LOA.xlsx`; feche o Excel antes de rodar.
- Demora muito → normal com OCR em documentos grandes; para um teste rápido, na aba `Parametros\_Gerais` da planilha de parâmetros, ajuste `USAR\_OCR = Nao`.

O QUE O PROGRAMA FAZ (RESUMO)

Lê os parâmetros → extrai texto dos PDFs (com OCR quando necessário) → busca o vocabulário → classifica em dois eixos (força × ancoragem) → pondera → deduplica → calcula os indicadores e o Grau de Integração Orçamentária → grava o Excel.

REPRODUTIBILIDADE

Vocabulário, pesos e rubrica idênticos aos Anexos A, B e C do `Texto-Tese-Modificado.docx`. Os resultados publicados na tese (item 4.3) foram gerados com Python 3.12, Tesseract 5 (idioma `por`) e as versões mínimas de bibliotecas listadas em `requirements.txt`. A amostragem do `Harness\_Validacao.py` usa semente fixa (`SEMENTE = 42`).